MP4 수행일지

이게 무엇인가

손님이 질문을 쓰면 상담봇이 안내문을 뜻으로 찾아 근거와 함께 답하고, 봇이 맡을 수 없는 질문은 가게 사장님에게 넘기는 고객센터입니다. 오 팀장(가이드 속 인물)이 휴가를 가도 되려면 — **「손님의 질문에 누가 답하나」**가 하나의 질문이었고, 이번에는 답이 맞는지를 **숫자로 재고 고칠 때마다 다시 재는 것**까지 갔습니다.

누가 쓰나	**손님 — 로그인 · 질문 · 답 보기 · 답마다 좋아요/별로예요**
	가게 사장님(담당자) — 안내문 올리기 · 봇이 못 답해 넘어온 질문(티켓) 보기
언제 만들었나	2026.10.30 ~ 11.03 (3일 · 미션 24개)
무엇으로	Firebase(Authentication · Firestore · Functions · Hosting · Storage · Emulator) · Gemini(`gemini-embedding-2` · `gemini-flash-lite-latest`) · GA4 · GitHub Actions
만들 때 쓴 것	Claude · VS Code(Claude Code)

주소

- 서비스 — https://haru-help-1104.web.app
- 결과 문서 — Claude Docs 문서 + PDF 2쪽(「미니4 보고서」)

화면 셋

화면	**누가**	**하는 일**
로그인	손님 · 사장님	이메일 또는 Google 로 들어옴. 처음 로그인하면 `users` 문서가 `customer` 로만 만들어짐
상담	손님	질문을 쓰면 답이 저절로 달림. 답 아래에 쓴 도구 · 근거 번호 · 좋아요/별로예요
관리	사장님	안내문 파일 올리기 · 티켓 표 · 새 티켓 알림 · 담당자 권한 받기

컬렉션 넷 — `users` · `questions` · `kb`(안내문) · `tickets`(봇이 못 답한 질문). 그밖에 시험용 `products` · `orders` · 올린 파일 기록 `kbFiles`.

숫자로 보면

미션	**24개 (M25 ~ M48) · 모두 본 과제 · 도전까지**
안내문	40장 + 올린 파일 1개(2장 더)
안내문 숫자	768개 (임베딩 차원)
봇이 쓰는 도구	4개 (내 주문 · 안내문 찾기 · 재고 · 사람에게 넘기기)
규칙 테스트	14개 · 통과 14 / 실패 0
검색 1위 정답	13/15 (Re-ranking 14/15 · 15/15)
도구 선택	12/12 (애매한 3개를 더한 15문항 14/15)
답 품질	27/30 · 사람 대조 3개 중 2개 일치
거절 시험	8/8 (교묘한 2개를 더한 10/10)
손님 반응	up 2 · down 1 (내가 시험으로 누른 값)
회귀 시험(CI)	통과 PR 13/15 · 실패 PR 10/15 · 기준 12
출시 전 점검표	8줄 · 판정 「연다 - 아직 0줄」
비용	예산 알림 1,000원 · 결제 보고서 10월분 ₩0
결과 문서	PDF 2쪽
테스트 기록	20건

이번에 지킨 것

손님 질문은 **본인 것만** 읽고 만들 수 있게 규칙을 썼고, 규칙 테스트 14개로 확인했습니다(허용 4 · 거부 10). Gemini 키는 비밀 저장소(Secret)에만 두고 화면 코드에는 넣지 않았습니다. GitHub 로 올릴 때는 `.secret.local` · `req-*.json`(UID 가 든 요청 파일)이 목록에 없는지 먼저 봤고, 있어서 막은 적이 한 번 있습니다. 돈이 새는 곳은 미리 닫았습니다 — 예산 알림 1,000원 · 함수 최대 개수 2 · 재시도 0 · 안내문 올리기는 담당자만 · 1MB 아래 · 글자 파일만 · 같은 파일은 다시 임베딩하지 않기(md5). 평가용 함수는 배포하지 않았습니다. 진짜 가게 `haru-jin-shop` 프로젝트는 건드리지 않았고, 같은 결제 계정에 묶여 있어서 결제 계정을 닫지 않았습니다.

이번 방식

MP3 와 같은 진행이었습니다. 가이드를 미션마다 한 장씩 받았고, 미션마다 갤러리에 결과물을 내고, 인계문서를 하루에도 여러 번 고쳐 가며 이어 썼습니다. 코드는 Claude Code 가 쓰고, 콘솔 · 터미널 · GitHub 는 내가 했습니다. 채팅의 AI 는 안내 · 평가표 O/X 초안 · 점수표 이유 초안 · 회고 초안을 줬고, 나는 그것을 읽고 붙였습니다. **어느 줄이 초안인지는 인계문서 5장에 적어 두었습니다.**

Day 1 (10/30 금) — 한 장으로 정하고, 길을 깔고, 처음 재 보기

오전

10:00 · MP4 시작

- 가이드가 말하는 「하루상점」이 내 가게 「진 빠지는 하루」라고 읽기로 함. 진짜 가게 프로젝트는 안 건드리고 새로 만든다

10:42 · M25 서비스 한 장

- 가이드를 받고 문제 · 대상 · 화면 셋 · 컬렉션 표(`users` · `questions` · `kb` · `tickets`)를 적었다
- 봇이 답할 것(배송 기간 · 세탁 방법 · 취소하는 방법)과 사람이 받을 것(환불 · 교환 · 할인 · 품절 재입고 · 내 주문 도착 · 배송 시작된 주문의 취소)을 나눔
- 11:14 새 AI 채팅에 한 장을 붙여 점검시킴. 짚힌 것 가운데 고칠 것만 고치고, 가이드가 이미 정의한 것은 안 고침 (`users` 의 role 은 처음 로그인할 때만 · `questions` 의 uid 는 본인 것만 · 「내 주문 언제 와요」는 사람)
- 11:15 본 과제 끝

11:18 ~ 11:21 · M25 도전

- 질문 다섯 개를 봇 / 사람으로 나눔. 「주문 취소 어디서 해요」는 방법 안내라 봇으로 정함

11:31 · M26 새 프로젝트

- 가이드(934줄)를 받음
- 11:50 프로젝트 이름을 `haru-jin-shop-help` 로 만들어 Step 5 까지 감 → 가이드의 이름(`haru-help`)과 달라 **다시 만들기로** 함 (T2)

오후

13:37 · M26 다시

- `haru-help` 로 프로젝트를 다시 만들고 Step 9 까지 끝냄(ID `haru-help-1104`)
- 13:38 Emulator UI overview 캡처 · 13:39 터미널 `All emulators ready!` 캡처(처음엔 상자만 나와 표까지 다시) · 본 과제 끝
- 13:47 도전 — 결제 계정에 묶인 프로젝트 3개 확인. 셋째 `My First Project` 는 내가 만든 게 아니라 처음에 자동으로 생긴 것

14:00 ~ 14:29 · M27 로그인 화면

- 콘솔에서 Authentication(이메일/비밀번호 · Google) · 승인된 도메인 · 설정 코드 · 규칙 한 벌
- 14:15 Claude Code 가 `public/index.html` 을 만듦. 14:17 에뮬레이터 `auth · firestore · hosting` 뜸
- 14:20 이메일 가입 → 로그아웃 → 로그인 · Google 로그인 시험. 14:21 에뮬레이터 UI 에서 계정 2줄 · `users` 문서(`name` · `role: customer`) 확인
- 14:23 본 과제 끝. 14:27 ~ 14:29 도전 — 로그인하면 이름 옆에 「손님」 / 「직원」

14:30 ~ 15:05 · M28 내 질문은 나만 — 규칙 + 테스트

- 14:36 규칙 빈칸 넷을 채워 저장(읽기 · 만들기 · `status == "waiting"` · kb 는 `if false`)
- 14:43 `rules.test.js` 14개 → `npm test` **14 / 14 통과**. 본 과제 끝
- 14:48 도전 — 열린 규칙(`firestore.open.rules`)으로 돌리니 **통과 5 · 실패 9**. 15:05 되돌려 다시 14 / 14

15:13 ~ 15:36 · M29 시험지와 첫 임베딩

- 15:18 평가표 15줄에 「낱말이 겹치나」 O/X 를 붙임 — X 5개(택배↔배송 · 적립금↔포인트 …)
- 15:25 `embedPair does not exist` → 15:28 `index.js` 맨 끝의 글자 v 를 지우고 다시 켬 (T3)
- 비슷한 짝 **0.668** · 상관없는 짝(택배 질문 ↔ 앞치마 세탁) 0.469. 15:29 본 과제 끝
- 15:32 ~ 15:36 도전 — 「교환 신청」 ↔ 「환불 신청」 문장은 **0.916**. 헷갈릴 수 있다고 적음

15:37 ~ 15:52 · M30 안내문 40장을 숫자로

- 15:40 buildKb → `saved 40 · dimension 768`. 15:41 에뮬레이터 UI 에서 kb 문서 · `embedding` 확인. 본 과제 끝
- 15:44 ~ 15:49 도전 — k41 을 더해 `saved 41` → 지우고 되돌리다 JSON 끝에 쉼표가 남음 (T4)
- 15:52 에뮬레이터에서 k41 삭제

15:55 ~ 16:22 · M31 뜻으로 찾기 · 기본 점수

- 16:01 searchKb — 1위 k33(거리 0.188). 16:05 q01 은 맞고 q07 은 틀림
- 16:10 evalKb → **1위 정답 13/15 · 3위 안 15/15**. 틀린 건 q07 · q12 (T6)
- 16:11 점수표에 앞 과정 방식(낱말 겹침 8/15 · 10/15, 가이드가 미리 잰 값)과 나란히 적음. 본 과제 끝
- 16:22 도전 — 낱말 겹침 X 였던 질문 5개 중 벡터가 1위로 맞힌 것 4개

16:20 ~ 17:45 · M32 하나만 바꿔 다시 재기

- 16:24 차원 768 → 128 로 바꿔 buildKb → evalKb 429(1분 한도) · 1분 뒤 다시
- 16:26 **15/15 · 15/15**. 이유 한 줄 — 15문항이라 2개 차이는 우연일 수 있다
- 16:28 768 로 되돌림 · buildKb dimension 768 확인. 본 과제 끝
- 17:43 ~ 17:45 도전 — 앞머리 글자 빼기(B)는 **11/15**. 4개가 틀림. 되돌림 확인

Day 2 (11/2 월) — 다시 고르고, 답하고, 도구를 쥐여 주고, 사람에게 넘기기

오전

10:41 ~ 10:57 · M33 Re-ranking

- 후보 10개를 Gemini 가 질문에 직접 답하는 순서로 다시 골라 3개. 에뮬레이터를 껐다 켜서 buildKb 768
- 10:53 evalKb **14/15 · 15/15** (q07 하나 틀림). 10:55 본 과제 끝
- 10:57 도전 — 같은 질문 · 같은 설정으로 한 번 더 → **15/15 · 15/15**. 돌릴 때마다 달라질 수 있음 (T8)

11:03 ~ 11:19 · M34 찾은 안내문으로 답하기

- 11:11 있는 질문 — 포인트로 일부 낸 주문의 환불 → 근거 k31 로 답함
- 11:12 없는 질문 「강아지 옷도 파나요?」 → 「안내문에 없는 내용이라 고객센터로 문의해 주세요」. 본 과제 끝
- 11:19 도전 — 그 답에 붙은 근거 k03(출고 마감 시각)은 강아지 옷과 상관없음 (T9)

11:22 ~ 11:41 · M35 채팅 화면

- 화면에 질문을 쓰면 questions 문서가 waiting 으로 생기고, 트리거가 답을 적어 answered 로 바꿈. 11:29 답이 달림(근거 k01)
- 11:31 지우고 다시 질문 — 「답을 찾는 중입니다…」 → 답. 11:33 문서에 필드 5개 확인. 본 과제 끝
- 11:40 ~ 11:41 도전 — 「지금까지 질문 N개」 (1개 → 2개)

오후

11:44 ~ 13:15 · M36 첫 도구 get_my_orders

- 11:44 시작 · 점심 쉼 · 13:09 seedShop → products 5 · orders 2 · 「제가 시킨 앞치마 어디쯤 왔어요?」→ 도구 get_my_orders. 본 과제 끝
- 13:15 도전 — 「제 주문 몇 건이나 있어요?」 → 같은 도구로 「총 2건」

13:18 ~ 13:31 · M37 도구 셋을 고르는 상담봇

- 도구 셋(안내문 찾기 · 내 주문 · 재고)으로 질문 세 개 → 세 도구가 각각 뜸
- 13:29 환각 대조 — 편수냄비 답의 「재입고 일정은 아직 정해진 바가 없습니다」는 데이터에 없는 말 (T11). 본 과제 끝
- 13:31 도전 — 「도마 재고 있으면 배송은 며칠 걸려요?」 → 도구 2개가 함께 뜸

13:34 ~ 13:48 · M38 도구 선택 재기

- 13:42 evalAgent **12/12** · 틀린 것 없음. 본 과제 끝
- 13:48 도전 — 애매한 3개를 더해 **14/15** · t15 「제가 산 앞치마 환불되나요?」를 안내문으로 풀었다 (T10)

14:00 ~ 14:19 · M39 실패 표시 · 0원 점검

- 14:07 일부러 실패시켜 화면에 빨간 글자 · 14:09 시험 줄 지움. 14:16 점검표 — 재시도 0 · maxInstances 2 · 키 무료 등급. 본 과제 끝
- 14:19 도전 — 실패한 문서에 status failed · error 만 남고 answer 는 없음

14:22 ~ 14:43 · M40 사람에게 넘기기

- handoff_to_human 도구 · tickets 규칙 · 관리 화면 · 브라우저 알림 허용
- 14:38 「어제 받은 앞치마에 얼룩이 있는데 바꿔 주세요」→ 담당자에게 넘김 · 표에 1줄 · 알림 1통. 택배 질문은 표가 그대로. 본 과제 끝
- 14:43 도전 — 「회사 행사용으로 서른 개 주문하면…」→ 표 2줄 · 알림 1통 더

Day 3 (11/3 화) — 점검하고 열고, 재는 법을 만들고, 내고 돌아보기

오전

10:00 ~ 10:50 · M41 점검하고 진짜 주소로 열기

- 점검표 틀 · 벡터 색인과 복합 색인 · 로그아웃 상태에서 `buildKb` 거절 · 담당자 권한 `grantStaff` 를 만들고 배포
- 10:40 공개 주소 https://haru-help-1104.web.app 에 올림. 관리 화면에 안내문 저장 40개 · 손님 채팅 답 · 티켓 1줄
- 손님 계정으로 관리 화면을 열면 티켓 0줄 · 두 버튼 `permission-denied` (T14). 점검표 8줄 중 「손님 반응 세기」만 **아직**
- 11:07 도전 — 새 손님 계정의 채팅 화면은 「지금까지 질문 0개」 (다른 손님 질문이 안 보임)

11:10 ~ 11:30 · M42 안내문 올리면 저절로 학습

- Storage 켜기 · `storage.rules`(담당자 · 1MB 아래 · 글자 파일) · `onKbUploaded` · 관리 화면 올리기 칸. 배포
- 11:22 `kb-new-items.txt` 를 올림 → `kbFiles` `chunks 2` · `kb` 문서 2장. 「강아지 옷도 파나요?」 → 18,000원 답
- 11:25 손님 계정으로 올리면 `storage/unauthorized`. 11:27 같은 파일을 다시 올리면 `updatedAt` 11:19:37 **그대로**. 본 과제 끝
- 11:30 도전 — 18,000원 → 20,000원으로 바꿔 올리니 `updatedAt` 11:29:41 · 새 답 20,000원

11:32 ~ 11:47 · M43 답마다 좋아요/별로예요 → GA4

- 새 GA4 속성 「하루상점 고객센터」 · 웹 스트림 · 측정 ID 연결. 답마다 버튼 · 누르면 두 버튼 잠기고 「고맙습니다」
- 11:41 실시간 개요에 `answer_feedback` **3** 도착. 11:42 up 2 · down 1(내가 누른 것). 점검표 마지막 줄이 **확인함** · 판정 「연다 - 아직 0줄」. 본 과제 끝
- 11:47 도전 — 맞춤 측정기준 답 반응 등록

11:48 · M44 가드레일 · 거절 시험 (시작)

- 거절 시험 파일 `guard-tests.csv`(8줄) · `AGENT_RULE` 에 가드레일 한 줄씩 · `evalGuard`

오후

13:11 ~ 13:27 · M44 이어서

- 13:11 에뮬레이터 `evalGuard` **8/8** (점심 사이 · 에뮬레이터 준비 시각은 채팅에 없음)
- 13:12 공개 주소 첫 답은 옛 규칙의 긴 거절 → 배포가 끝나기 전이었다 (T15). 13:13 다시 물으니 정해 둔 한 문장 「하루상점 상담만 도와드릴 수 있습니다.」. 본 과제 끝
- 13:27 도전 — 교묘한 인젝션 2개를 더해 **10/10**

13:29 ~ 14:13 · M45 AI 심판 · 사람 대조

- 기준표(`grounded` · `answered` · `cited` 각 1점) 로 10문항을 채점시킴 — 13:36 **27/30** · q07 만 0/3 (110초)
- 13:52 사람 대조 3개(q04 · q07 · q09) — q07 은 심판 0/3 · 나 1/3 (T16). **일치 2/3**. 본 과제 끝
- 14:13 도전 — 일부러 나쁜 답에 같은 기준표를 쓰니 0/3

14:15 ~ 15:15 · M46 평가를 CI 에

- 14:32 올리기 전 `git status` 에 `req-*.json` 9개가 보여 「좋아」를 막고 `.gitignore` 를 고침 (T17)
- 14:36 비공개 저장소에 올림. 14:43 통과 PR `pr-good` — 체크 초록 57초 · **13/15** (T18)
- 15:05 실패 PR `pr-bad`(제목만 임베딩) — 빨간 X · **10/15 - 기준 12 아래라 실패**. 15:07 합치지 않고 닫음. 본 과제 끝
- 15:15 도전 — 기준은 12 그대로. 이유 — 통과 점수 13에서 1점은 흔들림, 실패 10보다는 2점 위

15:17 ~ 16:17 · M47 결과 문서 한 편

- 15:17 Claude Docs 문서에 다섯 절 + 고도화 항목. 4절은 검색 · 도구 선택 · 답 품질 · 손님 반응 4줄 표
- 처음 4쪽 → 2.5쪽 → 2쪽으로 줄임. 이미지 2장은 한 문단에 나란히 (T19)
- 16:05 PDF 내보내기 · 사실 대조표 4줄 · 본 과제 끝
- 16:12 도전 — 처음 보는 PM 이 던진 질문 3개 중 하나(점수 기준이 빠져 있다)를 골라 4절 두 줄을 고침. 16:17 「2장 완성」

16:20 ~ 16:32 · M48 MLP 제출 · 회고

- 16:23 MLP 에 결과 문서 제출 → 「제출완료」 표시 확인. 회고 KPT 세 줄 적음
- 16:26 결제 보고서 — 10월분 ₩0 · 무료 체험판 크레딧 남음 (T20)
- 16:31 정리 판단 — 남긴다. 예산 알림은 걸어 둠. 본 과제 끝
- 16:32 도전 — 「다음 사람에게」 한 줄. 도전 끝

테스트 수행 일지

Day 1 (10/30)

[T1] AI 점검이 서비스 한 장의 빈 자리를 세 군데 짚음

수행 : 한 장을 새 AI 채팅에 붙여 세 항목(컬렉션 누락 · 손님이 쓰면 위험한 칸 · 사람 몫인 질문)을 점검

기대 : 빠지거나 어긋난 자리

실제 : `users` 의 role 을 이후에 고칠 때 · `questions` 의 uid · 주문 정보가 없어 답할 수 없는 「내 주문 언제 와요」가 짚임. 「안내문 = kb」는 가이드가 이미 정의한 것이라 짚을 거리가 아니었다

조치 : 한 장 세 줄을 고침(role 은 처음 로그인할 때만, uid 는 본인 것만, 사람 몫에 「내 주문 언제 와요」 · 「배송 시작된 주문의 취소」 추가)

재실행 : 반영한 뒤 다시 점검했다는 기록은 없음

판정 : 반영 확인 전

[T2] 프로젝트 이름이 가이드와 다름

수행 : Step 1 에서 이름을 `haru-jin-shop-help` 로 넣고 Step 5 까지 진행

기대 : 가이드의 `haru-help` (다음 미션들이 이 이름을 그대로 가리킴)

실제 : 이름이 달라 확인 항목 · 예산 적용 대상 표시와 어긋남. 프로젝트 ID 는 못 바꿈

조치 : 가이드 이름 `haru-help` 로 프로젝트를 다시 만듦(ID `haru-help-1104`)

재실행 : Step 9 까지 다시 진행 · 에뮬레이터 넷이 뜸

판정 : PASS (처음 프로젝트는 결제 목록에 없음을 도전에서 확인)

[T3] 함수가 에뮬레이터에 안 뜸 — 파일 끝의 글자 v

수행 : `index.js` 맨 아래에 한 줄을 붙이고 에뮬레이터를 켜 `embedPair` 를 부름

기대 : `dimension` 768 이 담긴 결과

실제 : `Function us-central1-embedPair does not exist, valid functions are:` — 함수 목록이 비어 있음

조치 : 컴퓨터의 `index.js` 를 읽어 보니 마지막 줄이 `…));v` 로 끝남. 붙여 넣을 때 글자 하나가 같이 들어갔다. `v` 를 지우고 에뮬레이터를 껐다 켬

재실행 : `dimension` 768 · `similarity` 0.668

판정 : PASS

[T4] 되돌린 뒤 JSON 이 안 읽힘 — 남은 쉼표

수행 : 도전 뒤 `kb-haru.json` 에서 `k41` 묶음과 앞 쉼표를 지움

기대 : `k40` 을 닫는 `}` 뒤에 쉼표 없이 `]`

실제 : `k40` 의 `},` 쉼표가 남아 `Illegal trailing comma before end of array.` 이 상태로 `buildKb` 를 부르면 `Unexpected token`

조치 : 파일을 읽어 찾고 쉼표만 지움

재실행 : 안내문 40장 · 마지막 `k40` · `k41` 없음 · 11,376바이트(원래와 같음)

판정 : PASS

[T5] 열린 규칙으로 돌리면 얼마나 떨어지는가 (M28 도전)

수행 : `firestore.open.rules`(누구나 읽고 쓰는 판)로 규칙 테스트 14개를 돌림

기대 : 막아야 할 거부 9개가 떨어짐

실제 : 통과 5 · 실패 9. 통과 5 는 허용 4개 + 로그인 안 한 사람의 읽기 거부 1개

조치 : RULES 를 `firestore.rules` 로 되돌림

재실행 : 통과 14 · 실패 0

판정 : PASS

[T6] 벡터 검색이 두 문항을 틀림

수행 : `evalKb` 로 15문항 채점

기대 : 정답 안내문이 1위

실제 : 1위 정답 13/15 · 3위 안 15/15. 틀린 것 — q07(정답 k17 · 1위 k16) · q12(정답 k31 · 1위 k32). 둘 다 포인트 이야기라 「쓸 수 있다」와 「쌓인다」, 「돌려받는다」와 「거둬 간다」를 못 갈랐다

조치 : 그날은 점수만 적음. 다음 단계에서 하나씩 바꿔 재기로 함(이유는 초안)

재실행 : 차원 128 로 바꾸니 15/15 · 15/15 (15문항이라 우연일 수 있음). 앞머리 글자를 빼니 11/15

판정 : 기본 점수로 확정

Day 2 (11/2)

[T7] 같은 설정의 Re-ranking 점수가 달라짐

수행 : `evalKb` 에 Re-ranking 을 켜고 두 번 돌림

기대 : 같은 질문 · 같은 설정이면 같은 점수

실제 : 첫 번째 14/15(q07 틀림) · 두 번째 15/15

조치 : 점수가 오른 게 아니라 흔들림일 수 있다고 적음. 생성 모델이 끼면 결과가 매번 다를 수 있다

재실행 : —

판정 : 기록만

[T8] 없는 질문의 근거가 맞지 않음

수행 : 「강아지 옷도 파나요?」 질문

기대 : 안내문에 없다는 답과 근거 없음

실제 : 「안내문에 없는 내용이라 고객센터로 문의해 주세요. (근거: k03)」. `k03` 은 출고 마감 시각이라 강아지 옷과 상관없음

조치 : 이유는 내 해석 — 검색이 거리와 상관없이 위 세 장을 돌려주고, 프롬프트가 답 끝에 `(근거: ID)` 를 붙이라 해서 근거가 없어도 1위 문서의 번호가 붙는다. 출처 번호는 사람이 확인해야 한다고 적음

재실행 : —

판정 : 기록만

[T9] 답에 데이터에 없는 말이 붙음

수행 : 「편수냄비 남아 있어요?」 질문

기대 : 데이터(`name` · `stock 0`)에 있는 말만

실제 : 「품절」은 맞는데 「재입고 일정은 아직 정해진 바가 없습니다」는 데이터에 없는 말

조치 : 환각 대조 한 줄로 지어낸 말이라고 판정해 적음. 서비스 한 장에서 재입고 시기를 사람 몫으로 둔 이유와 이어짐

재실행 : —

판정 : 기록만

[T10] 애매한 질문에서 도구를 잘못 고름

수행 : 12문항에 애매한 3문항을 더해 `evalAgent`

기대 : 정답 도구

실제 : 14/15. t15 「제가 산 앞치마 환불되나요?」는 정답 `get_my_orders`, 봇은 `search_guides`

조치 : 「환불」은 안내문에도 내 주문에도 나오는 말이라 쉬운 문제만 내면 점수가 높게 나온다고 적음. 더한 3줄은 지워 12줄로 돌림(내 말 · 확인 전)

재실행 : —

판정 : 기록만

[T11] 실패했을 때 손님 화면

수행 : 일부러 실패하는 질문 「실패 시험」을 보냄

기대 : 오류 글 대신 다시 물어봐 달라는 글만 보임

실제 : 빨간 글자 「답을 만들지 못했습니다. 잠시 뒤 다시 물어봐 주세요.」. 문서에는 `status failed` · `error` 연습용 실패 만 남고 `answer` 칸은 없음

조치 : 시험 줄은 지움. 점검표 — 재시도 0 · 함수 최대 2 · 키 무료 등급

재실행 : 보통 질문(택배)은 정상으로 답함

판정 : PASS

Day 3 (11/3)

[T12] 손님 계정이 관리 화면을 열 수 있는가

수행 : 시크릿 창에서 손님 계정으로 관리 화면을 열고 두 버튼을 누름

기대 : 막힘

실제 : 티켓 표 0줄 · 두 버튼 모두 `permission-denied`

조치 : 없음

재실행 : 새 손님 계정의 채팅 화면은 「지금까지 질문 0개」 — 앞 손님(담당자)의 질문이 안 보임

판정 : PASS

[T13] 키 검색에서 AIza 가 나옴

수행 : 점검표 「Gemini 키가 코드에 없다」 확인을 위해 VS Code 에서 `AIza` 검색

기대 : 키가 없음

조치 : Firebase 웹 키(apiKey)는 `firebaseConfig` 에 있는 게 정상(공개 값)이다. 안 보여야 하는 것은 Gemini 키뿐이므로 `functions/` 에 없는지만 봄

재실행 : `functions/` 에는 없고 `secrets` 이름만 있음(내 보고)

판정 : PASS

[T14] 손님이 안내문을 올리면

수행 : 손님 계정으로 같은 파일을 올림

기대 : 막힘

실제 : 화면에 `storage/unauthorized`

조치 : 없음

재실행 : 같은 파일을 담당자가 다시 올리니 `updatedAt` 이 그대로(`md5` 가 같아 임베딩을 건너뜀)

판정 : PASS

[T15] 배포가 끝나기 전에 시험함 (거절 한 문장)

수행 : 공개 주소에서 쇼핑과 상관없는 질문(고양이 시)을 부탁함

기대 : 「하루상점 상담만 도와드릴 수 있습니다.」 한 문장

실제 : 옛 규칙의 긴 거절

조치 : 배포가 아직 안 끝난 것으로 봄

재실행 : 배포가 끝난 뒤 같은 질문에 정해 둔 한 문장 · 도구 없음

판정 : PASS (조치 후)

[T16] AI 심판과 사람의 점수가 다름

수행 : q04 · q07 · q09 의 심판 점수를 내가 같은 기준표로 매겨 봄

기대 : 같은 점수

실제 : q04 · q09 는 같음(3/3). q07 은 심판 0/3 · 나 1/3 — `cited` 만 1점. 질문의 답(k17 에 1,000포인트부터)은 근거 번호에 적혀 있는데 답이 직접 말하지 않았다

조치 : 기준표의 「그 내용」이 답의 내용인지 질문의 답인지 애매했다고 적음. 내가 정답 문서 번호를 본 채로 매겼을 수 있음

재실행 : 일치 2/3

판정 : 기록만

[T17] 올리기 전 목록에 UID 가 든 요청 파일이 보임

수행 : GitHub 로 올리기 전 `git status`

기대 : 코드와 규칙 파일만

실제 : `req-ask.json` 등 `req-*.json` 9개가 목록에 보임(UID 가 든 파일). `.gitignore` 의 줄이 안 먹은 상태

조치 : 「좋아」를 멈추고 `.gitignore` 를 고침

재실행 : 목록에서 사라짐. `functions/` 안 `secret` · `node_modules` · `req-` 검색 결과 없음(내 말)

판정 : PASS

[T18] 고쳤더니 점수가 떨어지면 합치기 전에 알 수 있는가

수행 : PR 두 개 — 끝에 빈 줄 더하기(`pr-good`) · 제목만 임베딩(`pr-bad`)

기대 : 앞은 통과, 뒤는 빨간 X

실제 : 앞은 13/15 · 체크 초록 57초 · 뒤는 **10/15 - 기준 12 아래라 실패** · 빨간 X. 틀린 5개 q04 · q05 · q07 · q12 · q13

조치 : 실패 PR 은 합치지 않고 닫음. 기준 12 는 통과 13 에서 1점까지는 흔들림, 실패 10 보다 2점 위라는 이유로 그대로 둠

재실행 : —

판정 : PASS (비공개 저장소 + 무료 GitHub 에서는 기계가 합치기를 막지 못함 — 빨간 X 면 사람이 합치지 않는다)

[T19] 결과 문서가 2쪽을 넘음

수행 : 결과 문서를 PDF 로 미리 봄

기대 : 1~2쪽

실제 : 4쪽 → 줄이니 2.5쪽 → 2쪽 안에 들어와도 1쪽 아래 빈 자리에 이미지 두 장이 못 들어가 2쪽으로 넘어감

조치 : 1~2절 문장 · 3절 불릿 · 한계 줄을 줄이고 이미지 두 장을 한 문단에 나란히 둠

재실행 : PDF 2쪽

판정 : PASS

[T20] 결제 보고서에 내 프로젝트가 안 보임

수행 : Google Cloud 결제 보고서(서비스 · 이번 달)와 프로젝트별 표를 엶

기대 : `haru-help-1104` 의 금액

실제 : 10월분 ₩0. 프로젝트별 표에는 `haru-jin-shop` 만 나옴(사용 ₩12 · 기타 절감 -₩12 · 소계 ₩0). 계정 관리 화면에는 `haru-help-1104` 가 같은 결제 계정에 연결돼 있음

조치 : 아직 비용이 안 잡힌 것으로 봄. 같은 계정에 진짜 가게가 있어 결제 계정은 닫지 않음

재실행 : 내일 이후 다시 볼 일

판정 : 보류

발견하고 기록만 남긴 것

고치지 않았습니다. 범위 밖이거나 고치면 다른 곳을 바꿔야 하는 것들입니다.

발견	내용
서비스 한 장과 도구 설명이 다름	서비스 한 장은 「내 주문이 언제 오는지」 · 「품절 재입고」를 사람 몫으로 뒀는데, 이후 도구(`get_my_orders` · `get_stock`)로 봇이 직접 답한다. 경계가 두 곳에서 다르다
심판 기준표가 애매함	`cited` 의 「그 내용」이 답의 내용인지 질문의 답인지가 갈려 q07 점수가 사람과 달랐다
정답을 보고 채점했을 수 있음	사람 대조를 할 때 내가 붙여 넣은 줄에 정답 문서 번호(`k06` · `k17` · `k22`)가 들어 있었다
커밋에 공동 작성자 표시가 붙음	푸시를 Claude Code 로 해서 커밋에 `claude` 가 붙었다. MP3 의 「Co-Authored-By 없이」 규칙과 다르다
비공개 저장소에서는 기계가 합치기를 못 막음	무료 GitHub 등급이라 빨간 X 여도 합치는 버튼이 눌린다
처음 프로젝트가 남아 있을 수 있음	`haru-jin-shop-help` 는 결제 목록에 없고 무료 프로젝트로 남아 있을 수 있다(지울지는 내가 정함)
시험용 계정이 진짜 Auth 에 남음	도전에서 만든 손님 계정 두 개(`test3` · `tset4`)

못 한 것

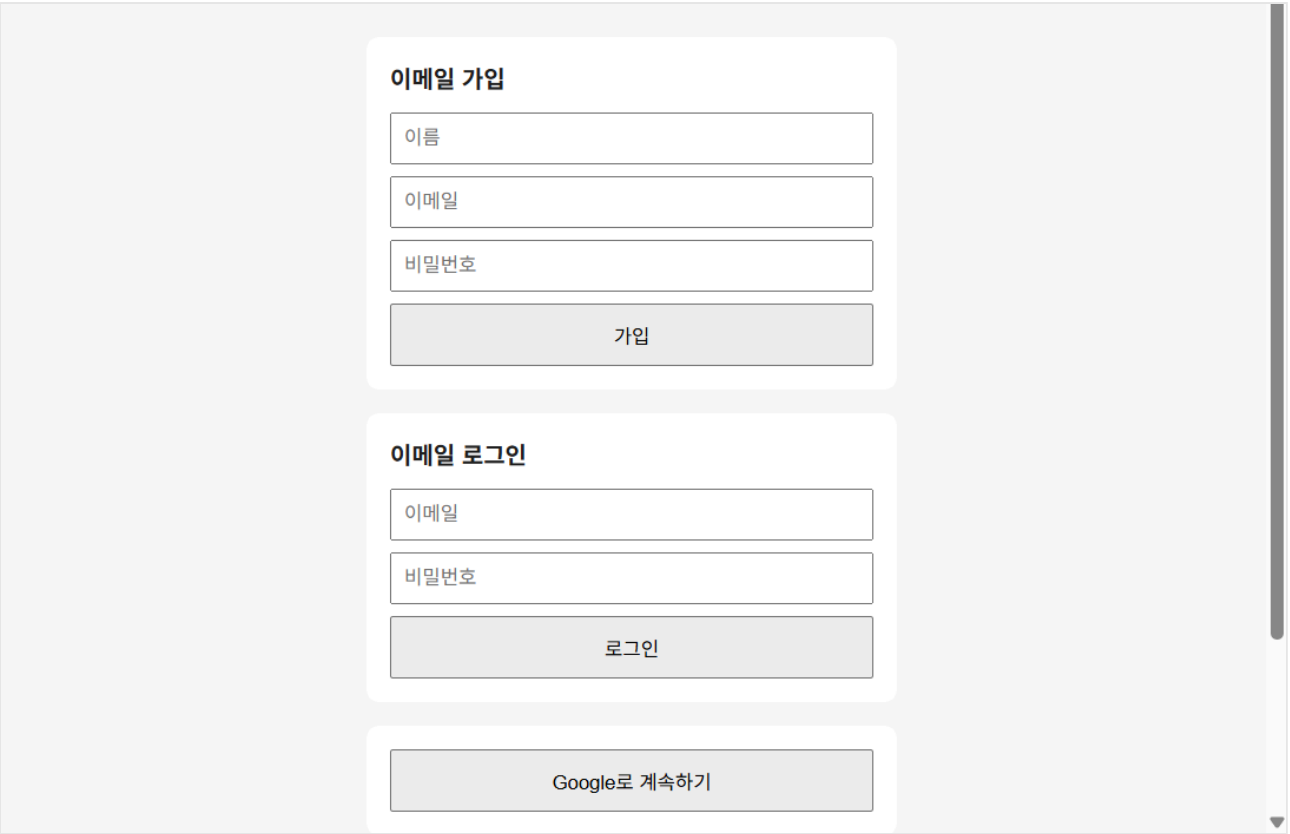
무엇	왜
실제 손님의 반응	up 2 · down 1 은 내가 시험으로 누른 값이다. 이벤트가 도착하는 것까지만 확인
낱말 차이(적립금 ↔ 포인트) 고치기	q07 이 계속 틀리는 이유를 알았지만 안내문을 고치지 않았다
평가 세트 늘리기	15 · 12 · 10 · 8문항이라 한 문항이 점수를 크게 바꾼다
질문 3 「실제 사용자 증거 없이 문제를 풀었다고 어떻게 말하나」	결과 문서의 한계에만 적고 고치지 않았다
확인 전으로 남은 것	결과 문서 4절 고친 문구 · 제출한 PDF 가 최신본인지 · `eval-tools.csv` 12줄 되돌림 · kb 42장 유지 · 예산 알림 설정(내 말)

결과 화면

1. 로그인 화면

https://haru-help-1104.web.app

이메일 가입 · 로그인과 Google 로그인. 로그인하면 이름 옆에 「손님」 / 「직원」이 붙는다.



2. 상담 화면

https://haru-help-1104.web.app

질문을 쓰면 답이 달린다. 답 끝에 (근거: …) · 아래에 쓴 도구 · 좋아요/별로예요.

지금까지 질문 3개

상담

질문을 입력하세요

보내기

강아지 옷도 파나요?

하루상점에서 강아지 리넨 조끼를 판매하고 있습니다. 크기는 소, 중, 대 세 가지이며 가격은 18,000원입니다 (근거: kb-new-items-1).

쓴 도구: search_guides

좋아요 별로예요 고맙습니다

강아지 조끼 얼마예요?

강아지 리넨 조끼는 한 벌에 20,000원입니다. 크기는 소, 중, 대 세 가지로 준비되어 있습니다. (근거: kb-new-items-1)

쓴 도구: search_guides

좋아요 별로예요 고맙습니다

택배는 보통 언제쯤 받아요?

결제를 마치시면 평일 기준 1~2일 안에 상품을 보내드리며, 발송 후 보통 하루 정도면 받아보실 수 있습니다. 단, 제주 및 섬 지역은 2~3일이 더 소요



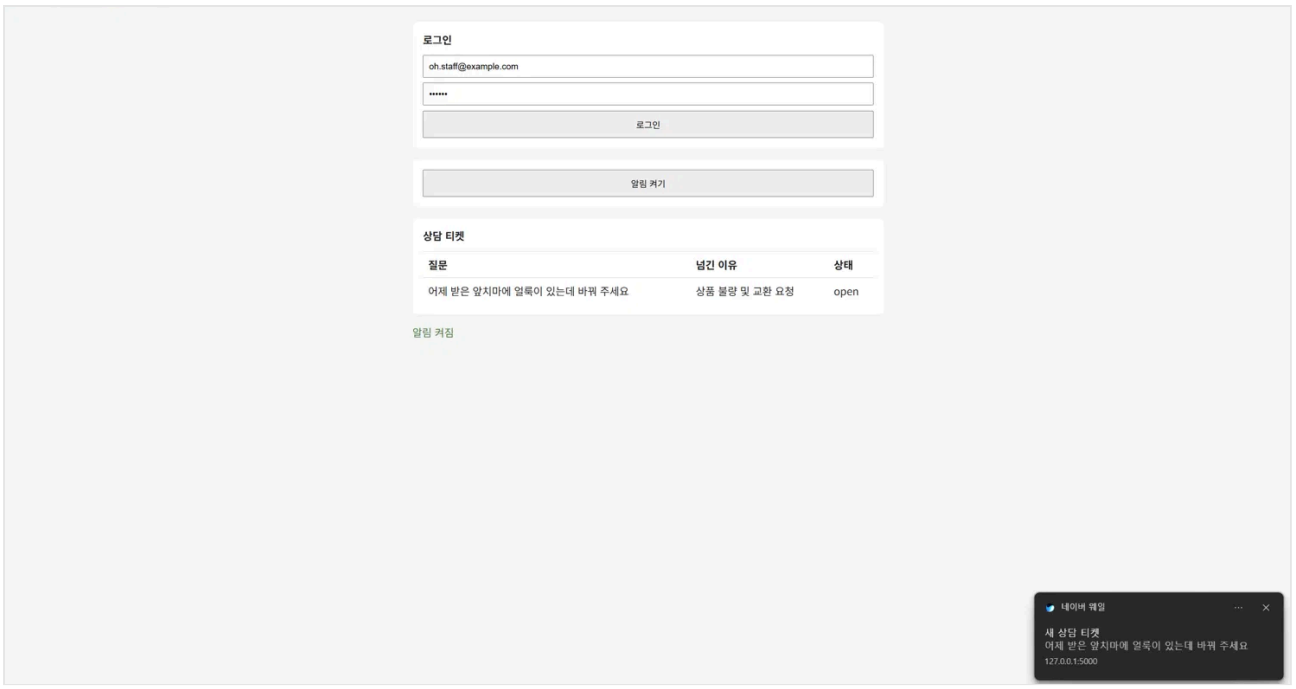
3. 관리 화면

안내문 올리기 칸과 상담 티켓 표. 「올렸습니다: kb-new-items.txt」.



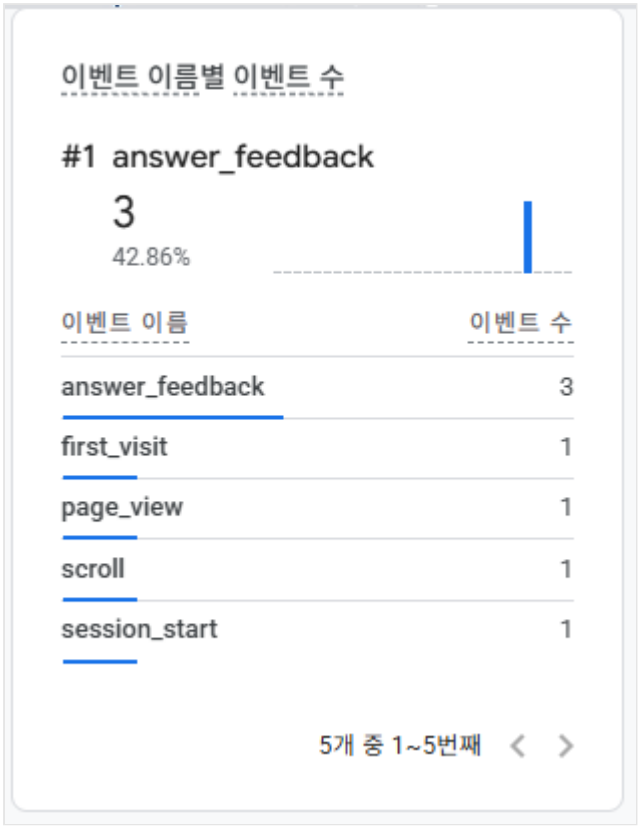
4. 사람에게 넘긴 티켓과 알림

「어제 받은 앞치마에 얼룩이 있는데 바꿔 주세요」 → 표 1줄 · open · 윈도우 알림.



5. GA4 — 답마다 좋아요/별로예요

실시간 개요에서 이벤트 `answer_feedback` 3.



6. 점수표 — 평가 결과

검색 13/15 · 도구 선택 12/12 · 답 품질 27/30 · 거절 8/8 · 10/10.

측정	점수	한 줄
검색	1위 정답 13/15	문항마다 정답 안내문 번호를 미리 정해 둔 15문항에서 1위가 정답인 수(Re-ranking 전). 3위 안 15/15. Re-ranking은 돌릴 때마다 14/15 · 15/15
도구 선택	12/12	애매한 질문을 더한 15문항은 14/15
답 품질	27/30	AI 심판 10문항 × 3점(항목 3개 grounded · answered · cited를 1점씩). 사람 대조 3개 중 2개 일치
손님 반응	up 2 · down 1	내가 시험으로 누른 값. 실제 손님 반응은 아직 없다

더 잰 것 : 거절 시험 8/8 · 10/10, CI 회귀 시험 통과 PR 13/15 · 실패 PR 10/15(기준 12)

7. 회귀 시험 — 통과 PR 과 실패 PR

초록 체크(13/15)와 빨간 X(10/15 - 기준 12 아래라 실패).

